

# Mémoire : Projet de Programmation

## Génération automatique de texte

Benoît Barthés  
Alexis Boumera  
Baptiste Guiomar  
Claire Pennarun  
Adrien Wintringer

Bordeaux 1  
Projet de Programmation

7 avril 2013

# Table des matières

<b>1</b>	<b>Présentation du sujet</b>	<b>3</b>
1.1	Présentation du domaine . . . . .	3
1.2	Présentation du projet . . . . .	4
<b>2</b>	<b>Etude de l'existant et bibliographie</b>	<b>7</b>
2.1	Eléments bibliographiques . . . . .	7
2.1.1	EasyText . . . . .	8
2.2	Etude de l'existant . . . . .	8
2.2.1	Projet GAT-2 . . . . .	8
2.2.2	Syntox . . . . .	9
<b>3</b>	<b>Cahier des charges</b>	<b>10</b>
3.1	Scénarios d'utilisation . . . . .	10
3.1.1	Scénarios utilisateur . . . . .	10
3.1.2	Scénarios administrateur . . . . .	11
3.2	Besoins fonctionnels . . . . .	11
3.2.1	Besoins utilisateur . . . . .	11
3.2.2	Besoins administrateur . . . . .	12
3.2.3	Besoins système . . . . .	13
3.3	Besoins non-fonctionnels . . . . .	14
3.3.1	Génération d'une entrée Syntox . . . . .	14
3.3.2	Facilité d'utilisation . . . . .	15
3.3.3	Portabilité . . . . .	15
3.3.4	Besoins relatifs aux bases de données utilisées . . . . .	15
<b>4</b>	<b>Architecture et implémentation</b>	<b>16</b>
4.1	Schémas de cas d'utilisation et de fonctionnement . . . . .	16
4.1.1	Diagramme de cas d'utilisation . . . . .	16
4.1.2	Schémas de fonctionnement . . . . .	19
4.2	Diagramme de packages . . . . .	21
4.3	Structures de données utilisées . . . . .	21
4.4	Communication avec la base de données . . . . .	21

4.5	Package Linguistic . . . . .	25
4.5.1	Package <code>concepts_gestion</code> . . . . .	25
4.5.2	Package <code>types_gestion</code> . . . . .	26
4.5.3	Package <code>graph_concepts_gestion</code> . . . . .	27
4.6	Génération de l'entrée Syntox . . . . .	28
4.7	Gestion des fichiers . . . . .	28
4.8	Problèmes rencontrés et remarques . . . . .	29
4.9	Diagrammes de séquence . . . . .	29
<b>5</b>	<b>Présentation du logiciel fourni</b>	<b>33</b>
<b>6</b>	<b>Tests et résultats</b>	<b>41</b>
6.1	Tests effectués . . . . .	41
6.1.1	Package Linguistique . . . . .	41
6.1.2	Core . . . . .	42
6.1.3	Database[Connection/Inspection] . . . . .	43
6.1.4	Syntox . . . . .	43
6.1.5	Mémoire et temps de calcul . . . . .	43
6.2	Résultats . . . . .	43
<b>7</b>	<b>Conclusion et perspectives</b>	<b>44</b>

# Chapitre 1

## Présentation du sujet

### 1.1 Présentation du domaine

Depuis l'apparition des ordinateurs dans les années 50, la question de la reproduction du langage naturel a toujours été une des plus épineuses.

En effet, le langage humain comprend une multitude de paramètres qui ne sont pas évidents à mettre en oeuvre en termes de programmation : syntaxe, grammaire, intonation, structuration de la pensée... Mais à quoi pourrait bien servir un ordinateur possédant le langage, puisqu'il ne possède pas la pensée, l'intention ; à quoi sert-il de savoir *parler* si l'on ne sait rien *dire* ?

La question est donc de savoir quoi faire dire à un logiciel, quel texte lui faire générer, et de quelle manière.

La génération automatique de texte est surtout un domaine où la machine doit savoir faire beaucoup de choix : choix du sujet à traiter, choix du vocabulaire à employer, choix de l'articulation des phrases... Tous ces choix doivent donc être guidés par le linguiste ou l'informaticien responsable du projet.

Les données analysées par le logiciel peuvent être de plusieurs types : tableaux de données financières (comme dans le système EasyText [3]), données statistiques ou météorologiques... Le traitement et l'analyse de données contenues dans une base de données est, par contre, un sujet qui a été très peu, voire pas traité dans le domaine de la génération de texte, sûrement en raison de la difficulté qu'il y a à extirper le sens de telles données.

Quant à la manière utilisée dans la génération de texte elle-même, elle peut également fortement varier : elle peut faire intervenir (ou non) un utilisateur externe, notamment pour l'étape de sélection du contenu pertinent dans les données initiales.

## 1.2 Présentation du projet

Le but du projet est de réaliser un logiciel permettant de générer du texte de manière automatique à partir de données brutes sélectionnées dans une base de données.

Pour se faire, nous utilisons le logiciel Syntox, qui est un logiciel développé par M. Lionel Clément, et qui génère du texte grammaticalement et syntaxiquement correct à partir d'une entrée d'une forme spécifique (dite *entrée Syntox* dans notre rapport). Syntox contient à l'avance une grammaire et un lexique qui correspondent au thème traité, ces deux composants étant fournis par M. Clément.

Le but de notre logiciel est donc de fournir à Syntox une entrée qui est ensuite transformée en texte.

Ce logiciel peut servir par exemple à analyser automatiquement des données contenues dans une base de données, ou à utiliser ces données intelligemment pour effectuer des tâches répétitives, notamment l'écriture de textes demandant une grande adaptation des termes suivant les situations (on peut penser au mailing automatique pour des commerciaux ou pour une administration, qui doivent adapter leur message à tous les types de destinataires).

La base de données considérée dans ce projet est une base de données relationnelle, contenant des informations intéressantes pour l'utilisateur, mais non exploitables directement ; il s'agit de données chiffrées, de fonctions, de relations, qui doivent être étudiées avant d'être interprétées.

La génération du texte se fait à partir de *scénarios utilisateur* : chaque scénario correspond à un but rhétorique visé par l'utilisateur.

Notre logiciel fait donc intervenir un utilisateur, qui peut construire le scénario voulu à partir de *concepts* : ceux-ci peuvent être une action, un événement, une succession, un objet, une personne... Le concept est complètement indépendant de la manière de le représenter (notamment indépendant du lexique utilisé, et même de la langue).

Les concepts dits "simples" ou atomiques, sont en général les personnes, ou les objets (ce qui correspond souvent aux noms propres ou aux noms communs). Dans l'exemple ci-dessous, les concepts "match" et "équipe" sont des concepts simples.

Par exemple, le concept "Gagner\_Match" peut être représenté ainsi :

$$\begin{bmatrix} \text{Gagner\_match} \\ \text{arg1} = \text{équipe} \\ \text{arg2} = \text{match} \end{bmatrix}$$

Les arguments d'un concept peuvent être eux-mêmes des concepts : cela permet de fabriquer des concepts plus complexes. Par exemple, le concept de causalité prend en argument deux concepts, qui sont complexes :

$$\begin{bmatrix} \text{cause} \\ \text{arg1} = \text{antécédent} \\ \text{arg2} = \text{conséquence} \end{bmatrix}$$

Dans notre projet, le logiciel propose à l'utilisateur de choisir entre la création d'un nouveau scénario (et l'utilisateur devra alors choisir les concepts qu'il veut exprimer, ainsi que leurs arguments) et la réutilisation d'un scénario déjà établi et sauvegardé.

Le scénario (c'est-à-dire l'ensemble de concepts plus ou moins complexes que l'utilisateur veut exprimer) est ensuite traité en plusieurs étapes par le logiciel pour générer l'entrée Syntox souhaitée.

Premièrement, le scénario est transformé en un *graphe conceptuel*, c'est-à-dire un graphe acyclique orienté dont les sommets sont des concepts et les arêtes orientées correspondent aux liens entre ces concepts.

Exemple de graphe conceptuel :



FIGURE 1.1 – La victoire du joueur1 dans le match1 entraîne sa victoire de la compétition A.

Ce graphe est ensuite parcouru pour le retranscrire en entrée Syntox.

Par exemple, le graphe ci-dessus provoque la génération de l'entrée suivante :

```

S Axiom[PRED=cause,
  arg1=[PRED=gagnerMatch,
    tense=present,
    subj=[PRED=joueur1, number=sg, def=+],
    obj=[PRED=match1, number=sg, def=+]],
  arg2 = [PRED=remporterCompétition,
    tense=present,

```

```
subj=[PRED=joueur1, number=sg, def=+],  
obj=[PRED=competition, number = sg, def=+]]
```

Chaque entrée permet à Syntox de générer toutes les phrases correspondant aux contraintes qui y sont spécifiées.

Dans notre exemple, Syntox génère alors les phrases :

1. le joueur1 gagne le match1 , par conséquent le joueur1 remporte la compétition .
2. le joueur1 gagne le match1 . le joueur1 remporte la compétition .
3. le joueur1 gagne le match1 , donc le joueur1 remporte la compétition .

On récupère ces phrases, qui correspondent au texte voulu par l'utilisateur. Celui-ci peut ensuite enregistrer le résultat dans un fichier.

Notre logiciel comporte deux types d'utilisateurs : l'utilisateur dit "classique", qui ne se préoccupe pas de la manière dont le texte est généré, et l'utilisateur administrateur, qui peut configurer le système.

Ainsi, l'administrateur peut configurer le système (créer les concepts requis et donner les informations de connexion à la base de données), puis l'utilisateur classique n'a plus qu'à utiliser le logiciel, sans avoir besoin de connaître la base de données utilisée ou les détails des concepts qu'il manipule.

# Chapitre 2

## Etude de l'existant et bibliographie

### 2.1 Eléments bibliographiques

L'état de l'art [1] présenté par John Bateman en 1993 (et mis à jour régulièrement depuis) concernant la génération automatique de texte est une base de connaissances très importante pour nous. En effet, l'auteur reprend les avancées des travaux les plus importants dans ce domaine, enrichi d'une grande bibliographie. Il donne également des méthodologies précises pour traiter des problèmes de la génération automatique de texte. Cet état de l'art, assez conséquent, nous permettra de trouver des références rapidement, même si le sujet que nous traitons n'a pas encore fait l'objet d'une étude poussée.

La synthèse du domaine faite par Laurence Danlos ([6]) est d'un grand intérêt pour notre projet. En effet il nous présente de façon très concise ce qu'est la génération automatique de texte. Le premier point intéressant concerne les questions qui se posent généralement dans les applications mettant en oeuvre de la génération de texte, "Quoi dire?" et "Comment le dire?". Ce seront probablement des questions que nous aurons à nous poser par la suite. Le document met aussi en avant les différents problèmes et difficultés rencontrés par les systèmes existants et auxquels nous pourrions avoir à faire face, mais aussi les avantages de tels systèmes. Il est par exemple question de leur "spécialisation" à certains domaines (comme la météo, les finances etc) qui leur permet de ne couvrir qu'une partie de la grammaire et du lexique et d'être ainsi relativement performants. Nous sont aussi présentés dans ce document les différents types d'applications déjà existantes, comme TA(O) (première application développée) ou encore PostGraphe (utilisé dans le domaine statistique). Plus intéressant encore, ce document nous décrit ce que peuvent ou pourraient apporter ces systèmes, comme par exemple une sortie orale (si nous couplions un générateur à un synthétiseur vocal). Une présentation précise des mécanismes et tâches mis en oeuvre dans la génération automatique nous est aussi offerte, avec pour chaque étape une présentation des entrées/sorties. Le document nous présente enfin le problème de l'évaluation de tels systèmes, qui s'avère difficile à résoudre



de par leur complexité.

### 2.1.1 EasyText

Le système de génération de textes EasyText [3] a été développé par Frédéric Meunier, Laurance Danlos, et Vanessa Combet dans le cadre d’une collaboration avec la filiale française Kantar Media de TNS-Sofres. Ce logiciel permet de créer un commentaire à partir d’un tableau de chiffres.

Contrairement à d’autres procédés de génération de textes tel que les textes à trous ou le publipostage, EasyText utilise un formalisme G-TAG. Ce dernier permet ”de transformer une représentation conceptuelle d’un ensemble d’informations en un texte” (d’après Laurence Danlos, [4]).

Plusieurs étapes ont lieu afin de réaliser le commentaire. Elles se schématisent par deux questions principales : ”Quoi dire ?” et ”Comment le dire ?” . Dans une première étape il faut sélectionner les informations que l’on peut dire : ce choix se fait en fonction des éléments intéressants présents dans le tableau. On obtient alors une conjonction de formules logiques, qui est ensuite transformée en un texte, en deux temps.

On cherche en premier lieu à transformer la conjonction en phrases (macro-planification). On s’appuie alors sur des connaissances rhétoriques et linguistiques de la langue pour structurer l’ordre du texte et déterminer ainsi le ”schéma” de la phrase. Enfin, on complète la phrase pour la former selon les conventions de la langue (micro-planification). Pour cela, en fonction du ”schéma” auquel elle se rapporte, on ajoute des déterminants, des compléments, etc en prêtant attention à la position à laquelle ils se situent. On s’appuie ici sur des connaissances sémantiques et syntaxiques. À la suite de toutes ses étapes on obtient un texte formé selon les critères de la langue qui a pour objet les éléments du tableau.

## 2.2 Etude de l’existant

### 2.2.1 Projet GAT-2

Le logiciel GAT-2 (Génération Automatique de Texte 2) [5] est le prédécesseur de notre objectif de travail actuel. Développé l’année dernière par 5 étudiants de master 1 Informatique, il repose principalement sur GAT-1 (développé lui aussi par des étudiants de master 1 Informatique) et sa version améliorée Syntox développée par Lionel Clément : ces deux outils ne se chargent pas du ”quoi dire” mais du ”comment le dire”, prenant en entrée des règles de grammaires énoncées de manière précise et générant un texte fini et syntaxiquement correct.

GAT-2, dans sa version finale, traite simplement une requête SQL énoncée par l’utilisateur (ou plutôt choisie dans une liste prédéfinie par les concepteurs), et y répond

via une phrase rédigée en français. Pour ce faire, il se connecte à la base de données, et traite via des opérations logiques simples la requête afin d'en extraire et d'en déduire plusieurs résultats, qui sont formatés de façon à pouvoir être interprétés par GAT-1 qui se charge d'écrire les données répondant à la requête initiale de l'utilisateur en plein texte. Cependant, il n'arrive pas pleinement à extraire le "sens" (au sens le plus strict du terme) de la base de données, se limitant à la réponse d'une seule question à la fois de manière assez redondante.

### 2.2.2 Syntox

Syntox [2] est un logiciel développé par Lionel Clément, chercheur au LaBRI dans l'équipe Méthodes Formelles.

Il est défini par son auteur comme un synthétiseur de texte. C'est un type de programme plutôt récent, il en existe donc peu et sont pour la plupart le fait d'universitaires.

Syntox permet de générer du texte à partir de concepts. En d'autres termes il ne vérifie pas qu'une phrase est correcte dans un langage donné, mais il crée une phrase correcte dans une grammaire et un lexique défini à partir d'idées.

Syntox ne se limite donc pas à la génération d'une unique phrase, et peut générer des paragraphes entiers. Sa limite principale se trouve dans les reprises sémantiques comme les anaphores, ou les ellipses. A l'heure actuelle, le projet représente deux ans de travail.

Son interface utilisateur est accessible via un navigateur web pour permettre de porter les efforts sur le programme en lui même et de ne pas perdre du temps à créer des exécutables pour différentes plateformes.

# Chapitre 3

## Cahier des charges

### 3.1 Scénarios d'utilisation

#### 3.1.1 Scénarios utilisateur

##### Scénario 1

1. L'utilisateur se connecte en choisissant le mode "utilisateur" ne requérant pas de mot de passe.
2. Il sélectionne le projet sur lequel il souhaite travailler, et entre le mot de passe de la base de données correspondante (si il y en a un).
3. Il choisit scénario existant et dans la liste déroulante il choisit celui qui lui convient en fonction de la base de donnée active .
4. Il clique sur le bouton "Valider" pour lancer l'exécution du logiciel.
5. L'utilisateur peut alors voir le résultat généré par le logiciel.
6. L'utilisateur enregistre le résultat dans un fichier texte en appuyant sur le bouton "sauvegarder".

##### Scénario 2

1. L'utilisateur se connecte en choisissant le mode "utilisateur" ne requérant pas de mot de passe.
2. Il choisit "scénario personnalisé" pour pouvoir commencer la création d'un scénario.
3. Dans l'écran de création d'un nouveau scénario, l'utilisateur peut choisir de rajouter ou de modifier les concepts qui composeront son scénario.
4. Il clique sur le bouton "Générer le texte" dans le menu "Fichier" pour lancer l'exécution du logiciel.

5. L'utilisateur trouve que le texte généré ne contient pas assez d'informations, ou des informations non pertinentes, il retourne à l'étape de choix des concepts et les modifie pour affiner le résultat en fonction de ce qu'il recherche.
6. Lorsque le résultat lui convient, l'utilisateur sauvegarde le scénario.
7. Enfin l'utilisateur enregistre le résultat dans un fichier texte.

### **3.1.2 Scénarios administrateur**

#### **Scénario 1**

1. L'administrateur choisit de se connecter en mode "Administrateur" et doit rentrer un login et un mot de passe.
2. Il choisit de créer un nouveau projet.
3. Il peut alors entrer le nom du projet, la base de données qui souhaite employer et les identifiants associés.
4. L'administrateur peut alors commencer la création du projet en choisissant les différents concepts qui seront liés à la base de données.
5. L'administrateur peut alors enregistrer son projet.

#### **Scénario 2**

1. L'administrateur choisit de se connecter en mode "Administrateur" et doit rentrer un login et un mot de passe.
2. Il choisit de modifier un projet.
3. Il choisit le nom du projet à modifier.
4. L'administrateur s'attelle à l'association de requêtes SQL avec des concepts nouveaux qu'il crée.
5. L'administrateur enregistre le projet.

## **3.2 Besoins fonctionnels**

### **3.2.1 Besoins utilisateur**

L'utilisateur classique doit pouvoir effectuer plusieurs actions de manière assez intuitive. Nous proposons donc une interface graphique pour accéder aux diverses fonctionnalités.

- Dans un premier temps, l'utilisateur peut sélectionner la base de données sur laquelle il souhaite travailler.
- L'utilisateur doit pouvoir créer un nouveau scénario ou charger un scénario pré-existant.

- Lors de la création d’un nouveau scénario, les différents concepts sont sélectionnés et une vue globale du scénario est proposée à l’utilisateur.
- La visualisation du texte généré se fait via l’interface graphique.
- Le résultat peut être enregistré dans un fichier .txt dont le nom est choisi par l’utilisateur. Ce fichier lui permet de réutiliser le texte généré à sa guise.

### 3.2.2 Besoins administrateur

L’administrateur est un utilisateur avancé qui peut configurer les différentes étapes de la génération du texte. Il possède un mode différent de celui de l’utilisateur classique dans l’interface graphique.

#### Besoins généraux

L’administrateur doit pouvoir :

- Lier les concepts à la base de données (par des requêtes SQL) via une interface graphique ;
- Choisir des concepts pertinents selon la base de données utilisée. L’administrateur va alors lier à chaque concept une ou plusieurs requêtes SQL nécessaire(s) à son expression ;
- Il a les mêmes besoins que l’utilisateur classique, et doit pouvoir accéder aux mêmes informations ;
- Il doit pouvoir visualiser le texte final, afin de pouvoir le vérifier et éventuellement modifier l’étape de liaison concepts/requêtes en cas de non-satisfaction.

#### Besoins liés à la base de données

D’un point de vue ”administration de la base de données”, l’administrateur doit pouvoir effectuer les actions suivantes :

- Ajouter des informations de connexion à une base de données ;
- Modifier les configurations de la base de données, ou changer son emplacement, ainsi que lui associer des profils utilisateur (identifiant/mot de passe) ;
- Vérifier le bon fonctionnement et retour des requêtes SQL utilisées ;
- Tester les requêtes directement sur le logiciel afin de vérifier leur bon fonctionnement.

#### Besoins liés aux concepts et aux scénarios

- *Créer/modifier/visualiser/supprimer des concepts*

Un concept étant un objet comprenant un nom (le nom du concept lui-même) et des arguments d’un nombre et d’un type précis, l’administrateur doit pouvoir entrer de nouveaux concepts dans la liste des concepts. La visualisation des concepts correspond à la visualisation du graphe conceptuel qui lui est associé.

– *Créer des scénarios*

L'administrateur doit pouvoir créer de nouveaux scénarios qui seront proposés à l'utilisateur s'il choisit de charger un scénario pré-enregistré.

Le client (M. Lionel Clément) se charge de la génération du lexique et de la grammaire associée au logiciel Syntox, il nous fournit également les concepts dont nous aurons besoin.

### **3.2.3 Besoins système**

Indépendamment des besoins fonctionnels de l'utilisateur classique et de l'utilisateur administrateur, nous avons des besoins fonctionnels relevant du système. Parmi ces besoins on trouve :

#### **Interface graphique**

Pour répondre aux besoins des utilisateurs classiques et administrateurs, l'interface graphique a pour fonction la création de l'entrée Syntox. Cette création du point de vue de l'utilisateur consiste à choisir, par le biais d'éléments graphiques, les concepts qu'il souhaite employer dans le texte final. Il peut choisir les concepts et leurs arguments, qu'ils soient simples ou complexes.

La fenêtre qui permet la création de l'entrée Syntox est commune à l'utilisateur classique et à l'administrateur. Tous deux ont les mêmes besoins pour cet aspect du programme, il n'est donc pas nécessaire de la dissocier.

L'utilisateur administrateur a accès à une fenêtre spécifique, consacrée à la gestion des concepts et des éléments de la base de données. Son rôle en tant qu'administrateur est de relier les concepts à des requêtes. Au moyen de cette fenêtre il pourra répondre à ce besoin fonctionnel.

#### **Génération de requêtes SQL**

On doit prévoir un module capable de communiquer avec la base de données au moyen de requêtes SQL : on doit donc être capable de les envoyer, et de recevoir la réponse de la base de données, ainsi que de traiter ces réponses pour pouvoir les utiliser.

#### **Base de données**

Nous avons besoin de pouvoir nous connecter à une base de données en lecture afin de pouvoir lire sa structure en lui soumettant des requêtes SQL. Pour le moment nous ne nous limitons pas à l'utilisation d'une seule base de données, afin de pouvoir étudier l'utilisation de différents concepts sur d'autres données.

Nous envisageons de stocker les concepts dans une base de données indépendante de celle où se trouvent les données initiales, pour pouvoir la transporter sans véhiculer l'ensemble des données.

### **Création du graphe conceptuel**

Pour la création du graphe conceptuel, nous avons besoin d'une librairie de graphes : nous devons pouvoir afficher le graphe, le modifier, le stocker en mémoire et le parcourir.

Ce graphe étant un graphe orienté acyclique, le parcourir pour générer l'entrée Syntox sera assez simple (un parcours en profondeur classique, en marquant les sommets déjà explorés).

### **Création de la requête pour Syntox**

Il s'agit ici de transformer le graphe conceptuel obtenu précédemment en entrée Syntox avec sa syntaxe spécifique. On crée dans ce but une table de correspondance entre chaque concept et l'entrée Syntox correspondante, modifiable par l'administrateur.

### **Génération de phrases**

On utilise Syntox afin de générer les phrases à partir de l'entrée créée par notre programme. On doit alors soit intégrer Syntox dans notre programme afin de lui communiquer directement les entrées, et les récupérer pour les stocker dans un fichier ; soit établir un protocole de communication avec la version en ligne de Syntox fonctionnant dans les deux sens : l'envoi de l'entrée et la récupération des phrases générées par Syntox.

## **3.3 Besoins non-fonctionnels**

Afin d'être conforme aux spécifications fournies par le client, le logiciel doit répondre à un certain nombre de besoins non-fonctionnels.

### **3.3.1 Génération d'une entrée Syntox**

- Le but premier du logiciel est de générer une entrée Syntox. Nous devons donc faire en sorte que cette entrée soit de forme compatible avec le logiciel Syntox. Pour ce faire nous devons avoir en mémoire un ensemble de règles qui relieront chaque concept exprimé au formalisme Syntox correspondant.
- L'entrée Syntox que le logiciel génère doit permettre la production d'une phrase grammaticalement correcte par Syntox, ce qui est assuré par une construction soignée et précise de l'entrée.

### **3.3.2 Facilité d'utilisation**

Le logiciel est conçu selon les besoins de notre client. Nous ne savons pas si d'autres personnes l'utiliseront. Nous partons donc avec l'objectif d'avoir un logiciel utilisable par une personne ayant des connaissances basiques en informatique. Cependant, il est à noter que pour l'administrateur, des connaissances en base de données sont souhaitées.

### **3.3.3 Portabilité**

Nous développons sous Linux et notre client utilise MacOS X, cela nécessite que notre programme soit le plus portable possible. Pour passer le moins de temps possible à compiler notre logiciel pour différentes plateformes ; l'utilisation d'une machine virtuelle est de ce fait nécessaire. Nous utiliserons l'environnement Java qui permet de combiner portabilité et simplicité. L'unique contrainte est Syntox mais il est utilisé via le réseau, donc il ne doit pas être compilé spécifiquement pour la machine de l'utilisateur final.

### **3.3.4 Besoins relatifs aux bases de données utilisées**

Pour les bases de données sur lesquelles on travaillera, on se limite aux bases relationnelles (SQL) car elles sont les plus répandues et permettent donc un travail sur des thèmes plus diversifiés. Cela permet également de disposer de plus d'outils pour les manipuler de par le nombre de librairies disponibles et d'un langage connu et normé, par rapport à des bases de données non SQL (souvent utilisées pour l'entrepôt de données comme les bases de données MongoDB) dont les outils sont moins accessibles. Dans le cas de bases de données non SQL, chaque base de données développe son propre langage, rendant la lecture par le même logiciel de plusieurs de ces bases impossible, ce qui ne les rend pas intéressantes dans le cadre de notre projet.

En conclusion nous nous limitons pour l'instant à une base de données MySQL, car il s'agit des plus répandues. En parallèle, on s'occupera de rendre notre logiciel adaptable au maximum à des bases de données relationnelles autres que MySQL, afin de rendre possible une extension du programme dans le futur.

Concernant le travail sur la base de données, nous nous contentons tout d'abord de connexions publiques (sans mot de passe) pour l'envoi des requêtes. On veut avant tout ne pas avoir à gérer un stockage de mot de passe car cela poserait des problèmes de sécurité (cryptage etc). On doit donc pouvoir effectuer des requêtes sur la base de données en tant que simple utilisateur, car on aura pas la possibilité d'une connexion en tant qu'administrateur.

En ce qui concerne les besoins internes à notre logiciel, il nous semble que l'utilisation d'une base de données est superflue.



# Chapitre 4

## Architecture et implémentation

### 4.1 Schémas de cas d'utilisation et de fonctionnement

Ils schématisent les interactions entre le programme, l'utilisateur et l'administrateur, avec la base de données et Syntox.

Avant tout, l'administrateur crée des concepts : ces concepts sont primordiaux pour la production finale de texte et régissent la manière dont est interrogée la base de données.

Il configure ensuite la connexion avec la base de données. Il se charge de la mise en place des requêtes SQL, et de leur association avec des concepts existants.

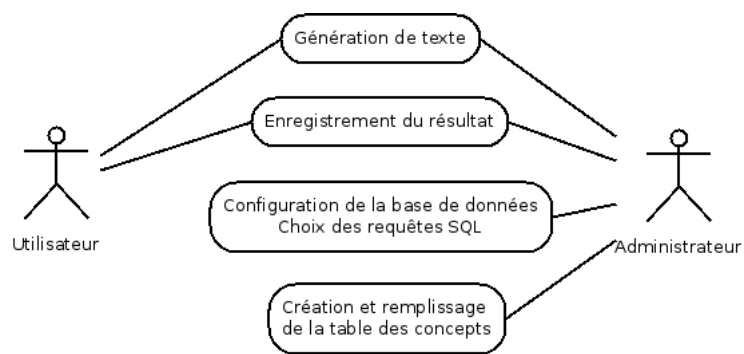
Il se doit de compléter la grammaire (s'il en existe une) et d'enrichir le lexique pour répondre aux concepts que l'on souhaite expliquer ; autrement dit, chaque base de données aura besoin de son propre lexique et éventuellement d'un ajustement de la grammaire pour obtenir un résultat satisfaisant.

L'utilisateur peut alors sélectionner un scénario ou interroger la base de données avec les outils proposés par l'IHM. Ses actions vont donner aux programmes les paramètres nécessaires à la création d'une entrée Syntox, après la récupération des informations nécessaires via des requêtes SQL. Syntox est alors sollicité pour générer un texte final.

A l'heure actuelle, on ne sait pas encore si le résultat final sera consultable uniquement via Syntox ou renvoyé à l'utilisateur via notre logiciel.

#### 4.1.1 Diagramme de cas d'utilisation

Ce diagramme présente les fonctionnalités accessibles à l'utilisateur classique et à l'administrateur.

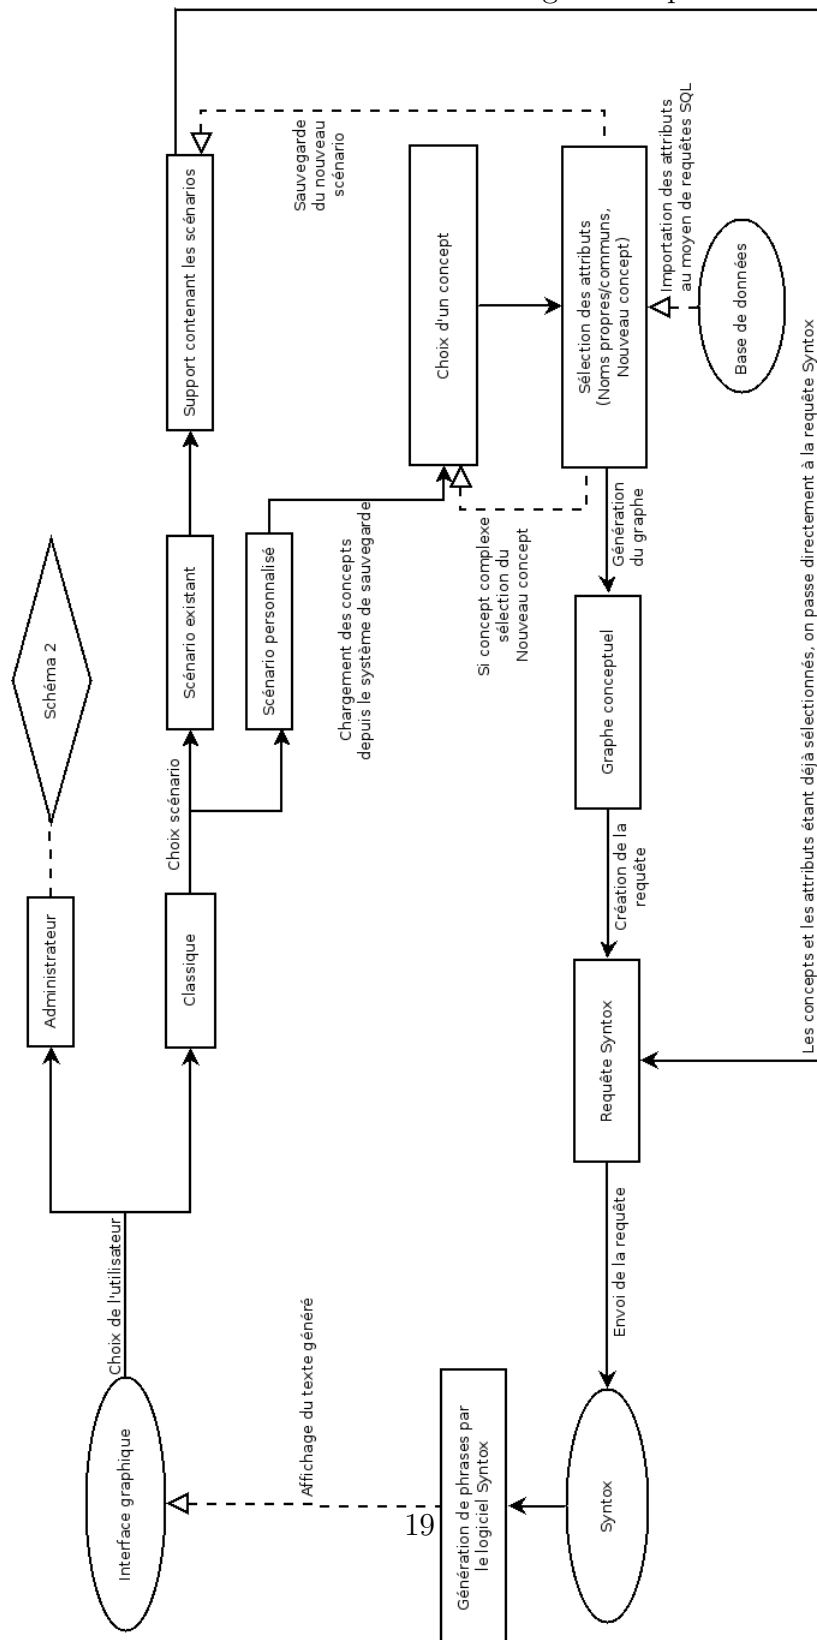




## 4.1.2 Schémas de fonctionnement


### Schéma de fonctionnement - Utilisateur

Le schéma suivant décrit le fonctionnement du logiciel du point de vue d'un utilis-



# Schéma de fonctionnement - Administrateur

Le schéma suivant décrit le fonctionnement du logiciel du point de vue d'un admin-



Notre programme se composera de cinq packages principaux : Database, Linguistic, FileManager, SyntoxConnection et IHM, correspondant aux différentes fonctionnalités du programme. Chacun de ces packages comportera les classes nécessaires à son bon fonctionnement.

## 4.2 Diagramme de packages

Le diagramme suivant présente la structure générale du logiciel.

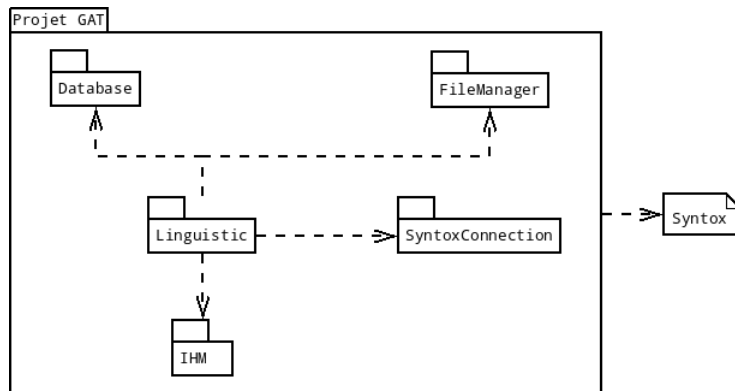


FIGURE 4.1 – Diagramme de packages

## 4.3 Structures de données utilisées

## 4.4 Communication avec la base de données

### Package databaseInspection

- Interface Base : Cette interface sera implémentée par BaseImpl. Elle contient les tables et leurs relations(jointure).
- Interface Table : Cette interface sera implémentée par TableImpl. Elle représente une table et contient les liste de ces colonnes.
- Interface Column : Cette interface sera implémentée par ColumnImpl. Elle représente une colonne d'une table.
- Interface JoinTable : Cette interface sera implémentée par JoinTableImpl. Elle représente la liaison entre deux table.
- Interface BaseFactory : Cette interface sera implémentée par BaseFactoryImpl. elle construit un objet Base à partir d'une base de données SQL.

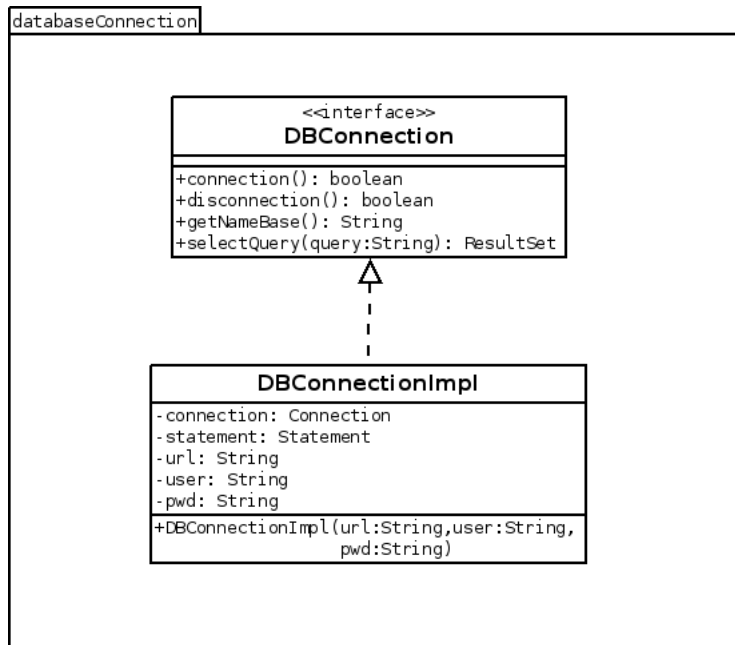


FIGURE 4.2 – Diagramme du package BaseDonnées

- Interface CookingRequeste : Cette interface sera implémentée par CookingRequesteImpl. Elle construit une requête SQL.
- Interface AgloTable : Cette interface sera implémentée par AgloTableImpl. Elle calcule la jointure minimal entre plusieurs table.

### Package databaseConnection

- Interface DBConnexion : Cette interface sera implémentée par DBConnexionImpl. Elle contient les outils nécessaire à la connexion aux bases de données.

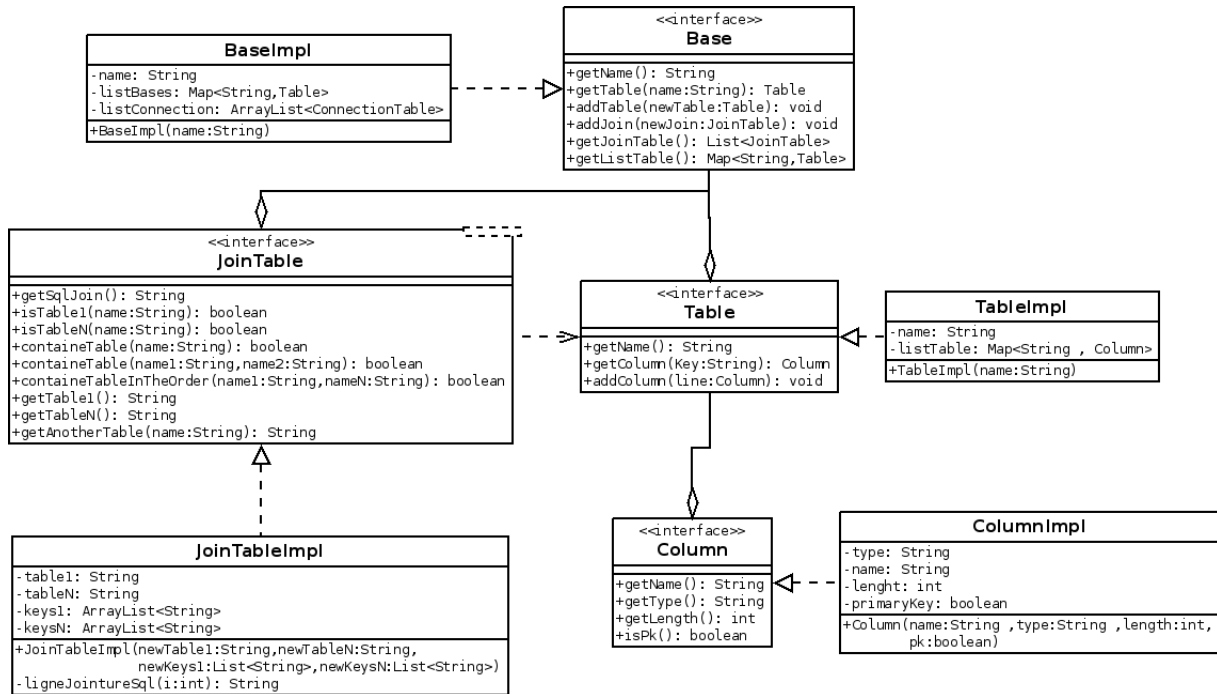


FIGURE 4.3 – Diagramme du package database Inspection partie structure

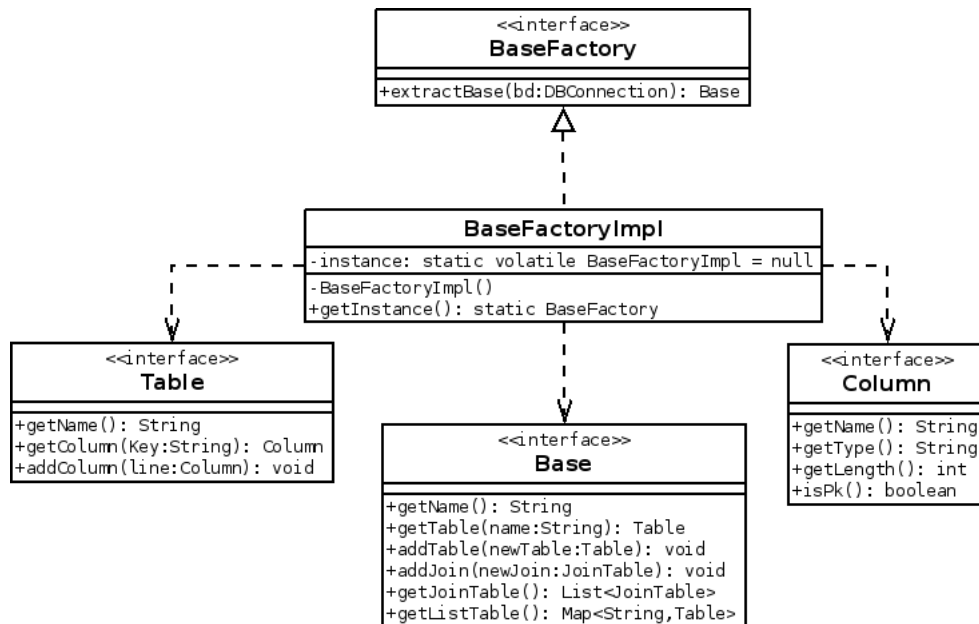


FIGURE 4.4 – Diagramme du package database Inspection partie génération de la structure



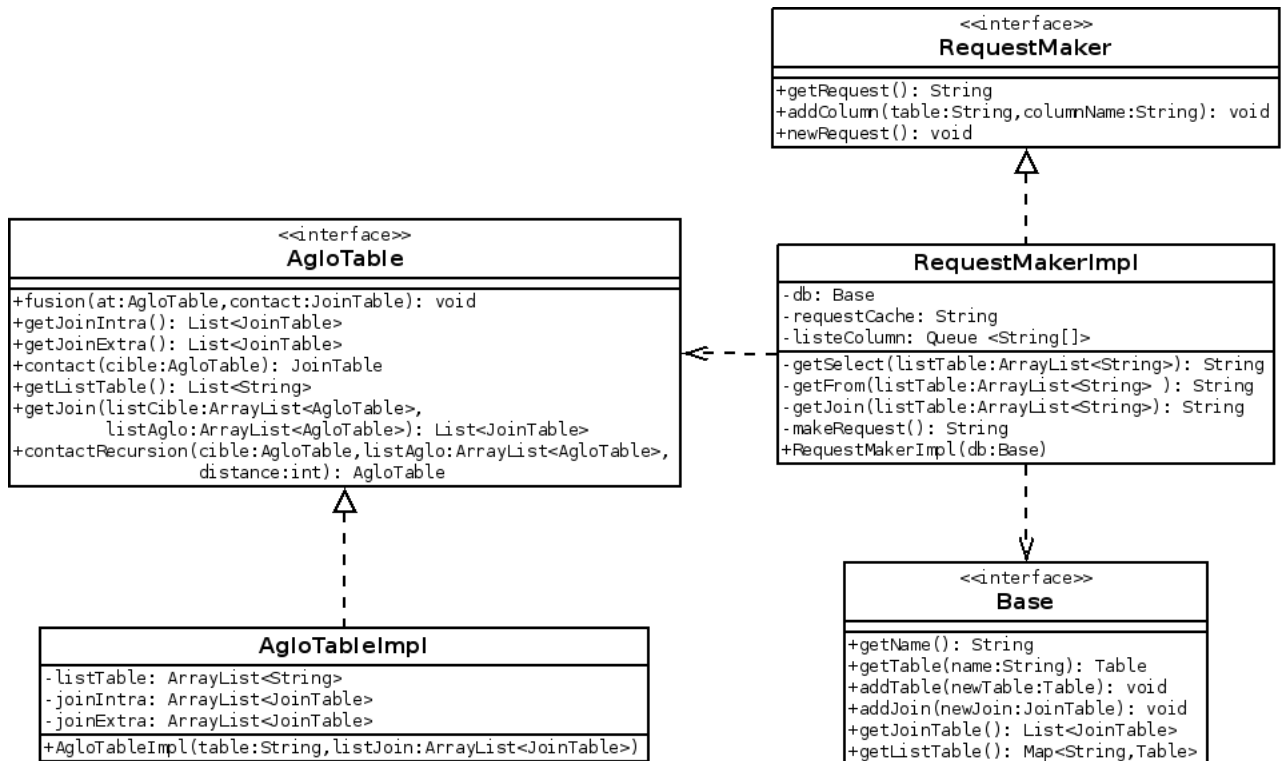
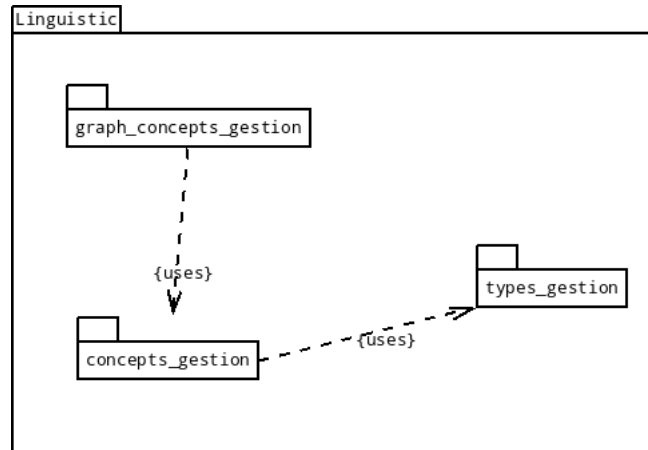


FIGURE 4.5 – Diagramme du package database Inspection partie génération de requête sql

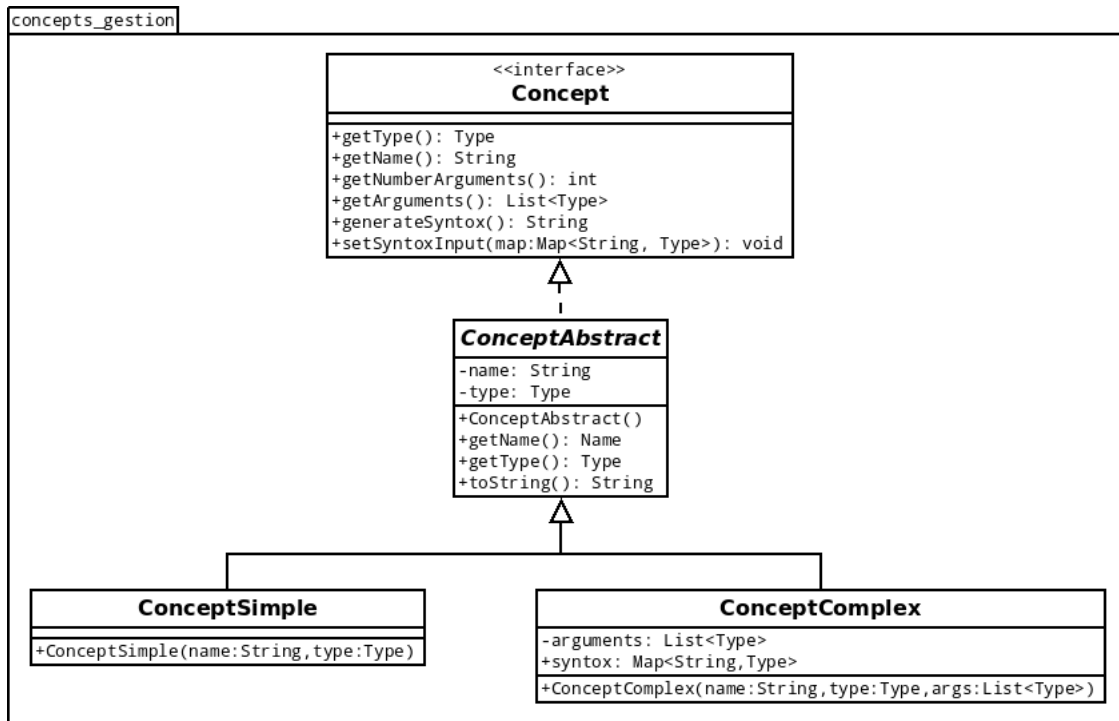
## 4.5 Package Linguistic

Ce package comprend toutes les classes nécessaires à la gestion des concepts, la mise en place d'un système de typage et la génération du graphe conceptuel correspondant au scénario généré par l'utilisateur.

Le package `linguistic` a été subdivisé en trois sous-packages : `concepts_gestion`, `types_gestion` et `graph_concepts_gestion`.



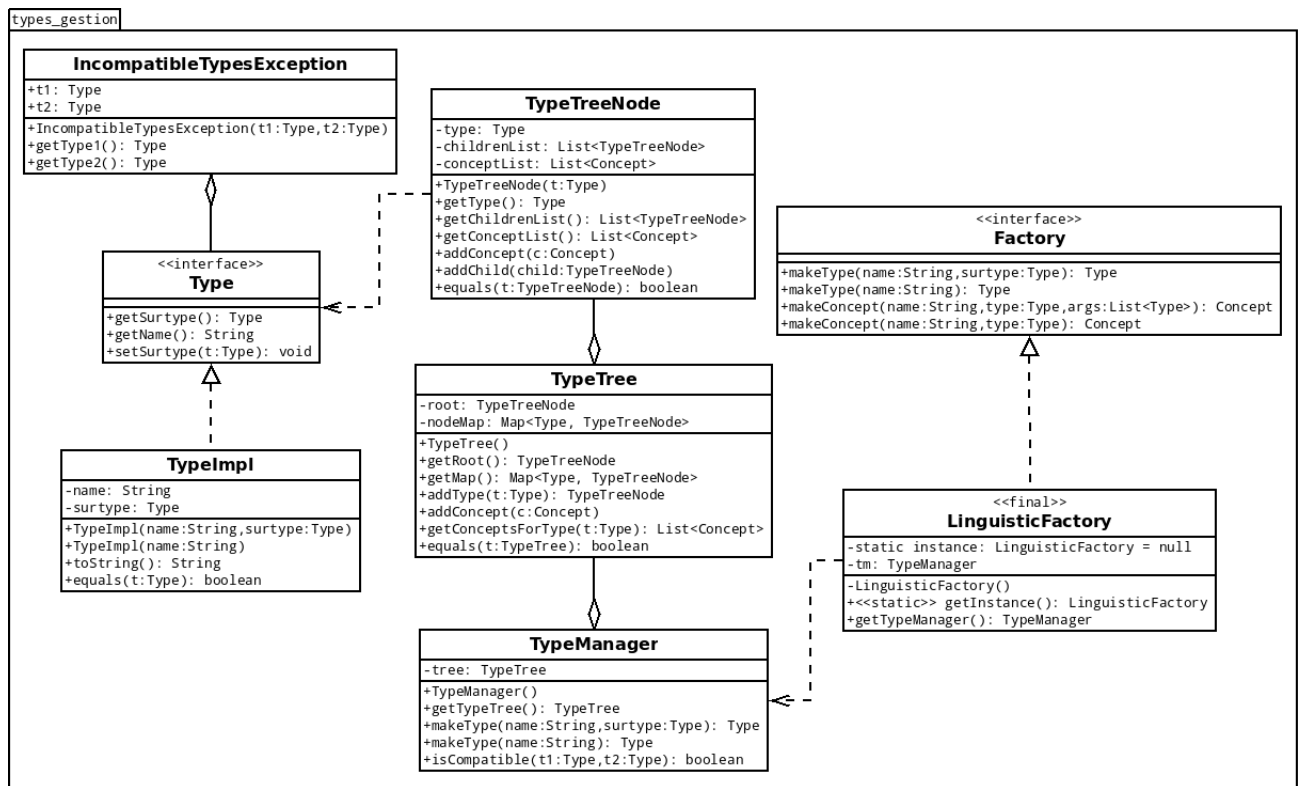
### 4.5.1 Package concepts\_gestion



Ce package contient la structure représentant un concept. Chaque Concept est défini par (au moins) un nom et un Type. Le Concept peut être simple ou complexe ; s'il est complexe, il possède également une liste d'arguments (qui sont des types, ce qui permet une indépendance des différents concepts).

La classe ConceptAbstract permet de factoriser du code, notamment les accesseurs. La méthode generateSyntox sera analysée dans la partie "Génération de l'entrée Syntox".

#### 4.5.2 Package types\_gestion



Le package `types_gestion` contient les classes gérant le système de typage des Concepts. Le coeur de ce package est donc bien sûr l'interface `Type` et la classe `TypeImpl` qui l'implémente. Chaque `Type` peut être relié à d'autres types par une relation surtype / sous-type.

Les `Types` sont stockés dans un arbre de types, implémenté par la classe `TypeTree`. Cet arbre de types contient une référence à la racine de l'arbre (qui correspond au `Type` racine), et une `Map` qui permet de faire la correspondance entre un `Type` stocké dans l'arbre et le noeud de l'arbre qui contient ce type. Nous avons choisi d'implémenter cette correspondance avec une `Map` car c'est une structure qui permet une indexation par les `Types`, et un accès rapide en lecture.

L'arbre de types `TypeTree` est composé de plusieurs `TypeTreeNode`, chacun correspondant à un Type précis et une liste de Concepts ayant ce Type. Chaque `TypeTreeNode` comprend aussi une liste des `TypeTreeNode` qui sont "en-dessous" de lui dans l'arbre de types.

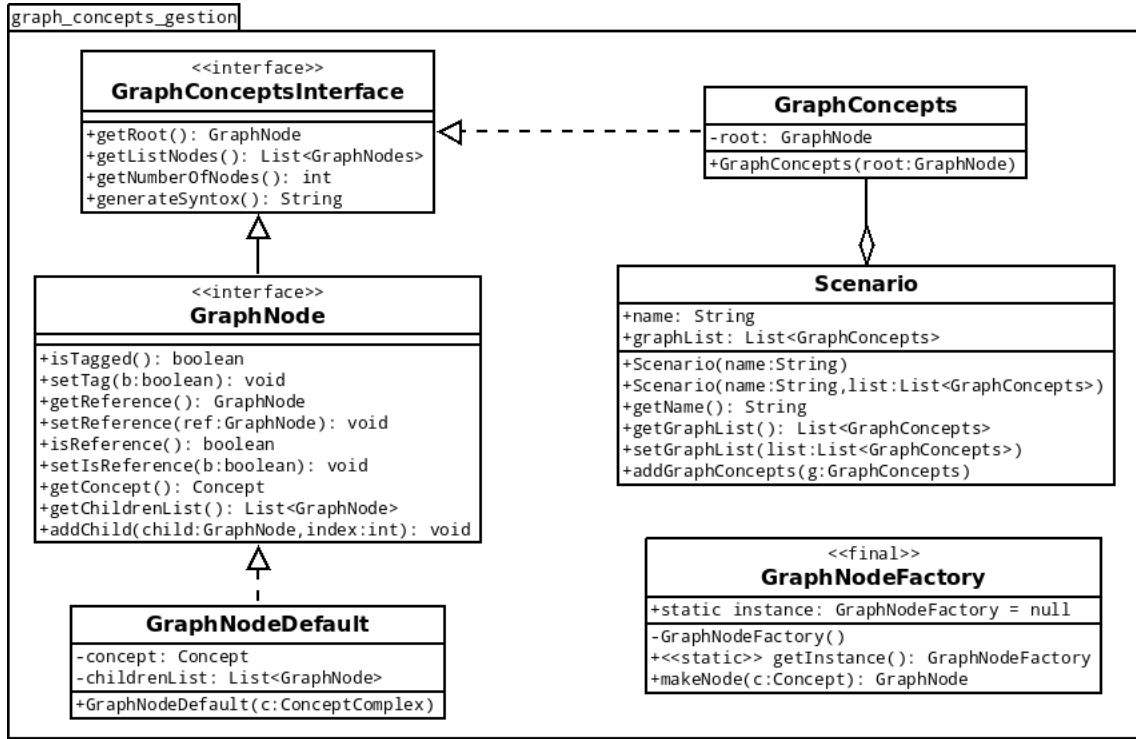
Cette connaissance par chaque `TypeTreeNode` de ses fils permet au `TypeTree` de parcourir les `TypeTreeNode` à partir de la racine, ce qui sert notamment pour l'implémentation de la méthode `getConceptsForType(Type t)`, qui retourne une liste des Concepts ayant le Type `t` ou un de ses sous-types.

La classe `TypeManager` est une classe qui permet de gérer et d'instancier les types, elle se base sur le modèle du pattern Factory. En effet, l'instanciation des types est faite par le `TypeManager`, qui crée et modifie dynamiquement l'arbre de types correspondant. Il est aussi responsable de la compatibilité de deux Types `t1` et `t2`, c'est-à-dire la vérification que le Type `t1` est un sous-type (strict ou non) du Type `t2`.

L'arbre de types et donc la classe `TypeManager` ne doivent avoir qu'une seule instance par Projet, nous avons donc mis en place la classe `LinguisticFactory`, qui se base sur le pattern Singleton, pour gérer la création de nouveaux Type et de nouveaux Concept. C'est cette classe qui sera utilisée lors de l'instanciation des Type et des Concept, et qui "cachera" à l'utilisateur le système de gestion et de stockage des Type et des Concept.

Le package `types_gestion` comprend également une classe d'exception `IncompatibleTypesException`, qui permet de gérer l'incompatibilité de deux types.

### 4.5.3 Package graph\_concepts\_gestion



## 4.6 Génération de l'entrée Syntax




FIGURE 4.6 – Diagramme du package ConnexionSyntax

## 4.7 Gestion des fichiers

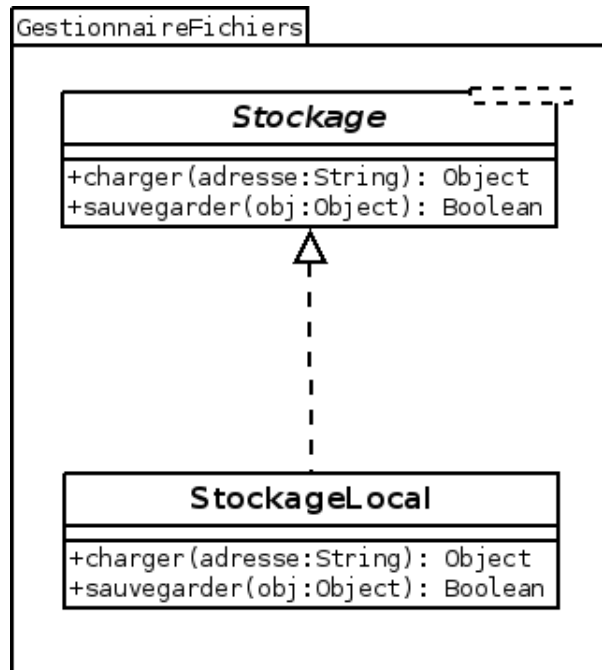
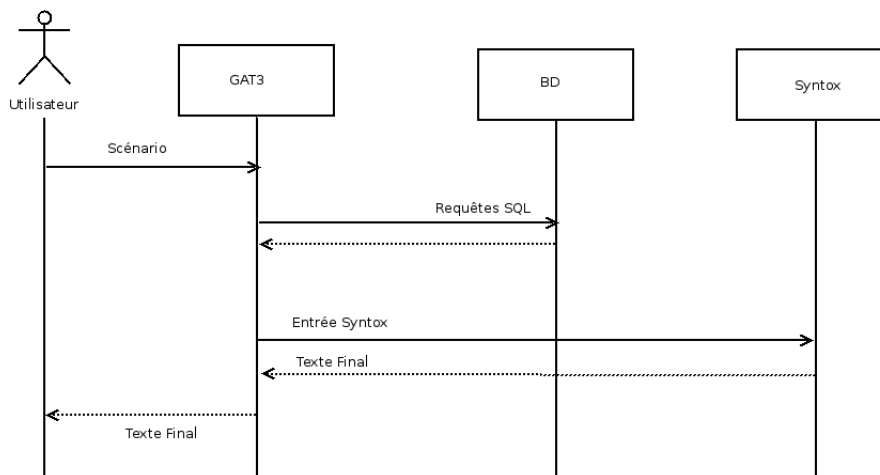


FIGURE 4.7 – Diagramme du package GestionnaireFichiers

## 4.8 Problèmes rencontrés et remarques

## 4.9 Diagrammes de séquence

Ce diagramme de séquence explicite les étapes de configuration de la base de données, du lexique et de la grammaire par l'administrateur.






FIGURE 4.8 – Diagramme de séquence Scénario 1




FIGURE 4.9 – Diagramme de séquence Scénario 2






FIGURE 4.10 – Diagramme de séquence Scénario 3

## Chapitre 5

### Présentation du logiciel fourni




FIGURE 5.1 – Ecran de connexion




FIGURE 5.2 – Ecran d'ouverture d'un projet




FIGURE 5.3 – Ecran de sélection de scénario existant/personnalisé




FIGURE 5.4 – Ecran de sélection de scénario existant




FIGURE 5.5 – Ecran affichant le texte généré




FIGURE 5.6 – Ecran de création d'un nouveau scénario




FIGURE 5.7 – Ecran de connexion à la partie administrateur

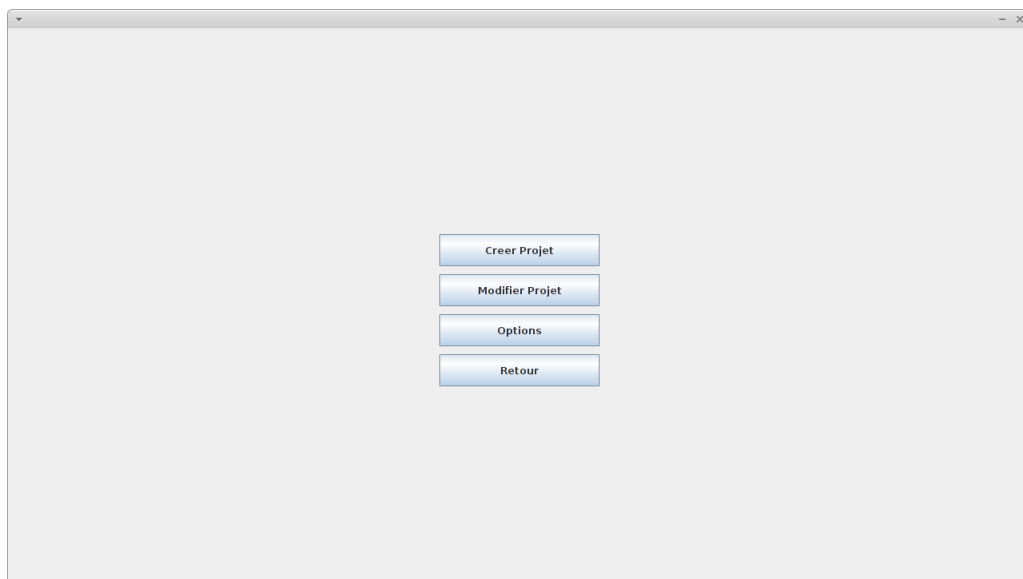


FIGURE 5.8 – Ecran du menu administrateur




FIGURE 5.9 – Ecran de création d'un nouveau projet

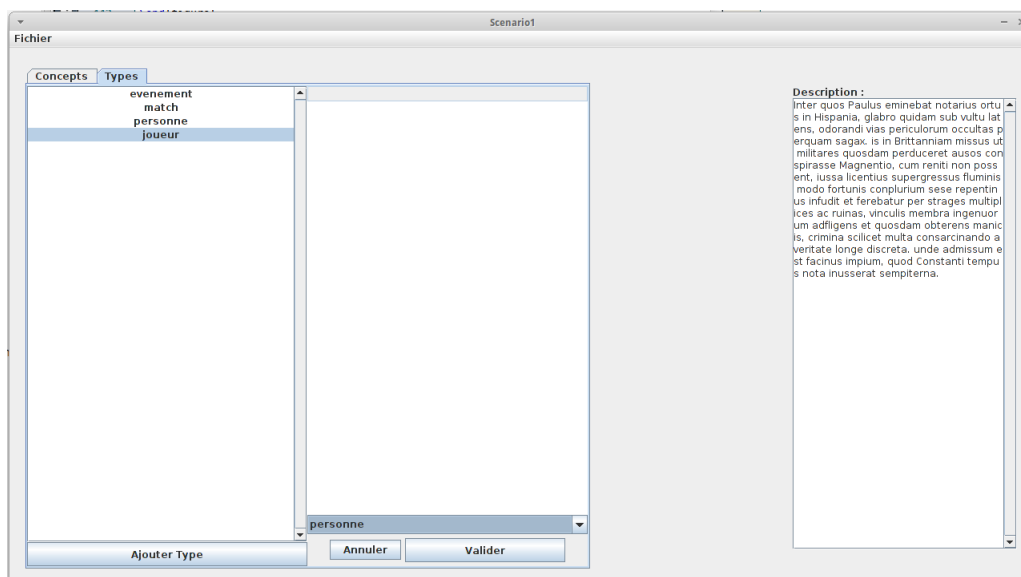


FIGURE 5.10 – Ecran de création des types




FIGURE 5.11 – Ecran de création des concepts




FIGURE 5.12 – Ecran de choix du projet à modifier






FIGURE 5.13 – Ecran de choix des attributs

# Chapitre 6

## Tests et résultats

### 6.1 Tests effectués

Le but de ces tests est d'assurer le bon fonctionnement de notre application. Nous pouvons les regrouper selon l'ensemble de fonctionnalités auxquels ils se rattachent. Afin de ne pas mélanger le code source et les essais, nous avons créé un package différent regroupant l'ensemble des classes et méthodes de test.

#### 6.1.1 Package Linguistique

Ce package regroupe les principaux objets utilisés par l'interface graphique tels que les concepts, graphes, noeuds et système de typage des concepts. Son bon fonctionnement était donc primordial pour ne pas avoir d'erreurs lors de l'utilisation de ces derniers par l'interface graphique. Nous avons donc élaboré des tests unitaires, au moyen de JUnit, sur chacune des classes et méthodes.

- `ConceptTest` : Permet de tester les classes `Concept`(`Abstract/Complex/Simple`). Dans ces classes nous avons majoritairement des accesseurs mais également des méthodes utilisées pour la génération de l'entrée `Syntox`. Notons que les accesseurs ne sont normalement pas des éléments soulevant des problèmes. Toutefois nous nous sommes assurés que les éléments retournés sont bien ceux attendus, surtout dans le cas de la liste et du nombre d'éléments qu'elle contient. Concernant la méthode `generateSyntox()` nous avons choisi de la tester plus tard dans une autre classe qui utilise une méthode identique mais depuis un objet `"GraphConcepts"` et qui fait appel à cette méthode.
- `TypeTest` : Permet de tester la classe `TypeImpl` qui implémente `Type`. Nous avons ici testé de manière similaire à `"ConceptTest"` les accesseurs présents en plus de la méthode `"equals"` dont nous avons besoin.
- `TypeTreeTest` et `TypeTreeNodeTest` : Les tests présents dans ces classes se rapportent respectivement aux classes du même nom, `TypeTree` et `TypeTreeNode`.

Comme nous l'indiquent les commentaires, ces dernières permettent de représenter sous forme d'arbre, l'organisation et les liaisons des différents types. Nous avons fait le choix de tester l'intégralité des méthodes présentes dans ces classes, à savoir :

- L'ajout d'un nouveau concept à la liste du noeud en question.
- L'ajout d'un fils à la liste concernée.
- L'ajout d'un type dans l'objet TypeTree (Plus précisément dans la Map de l'objet) en respectant les liaisons avec un type prédécesseur (surType). De façon similaire, l'ajout d'un concept à ce même objet.
- La méthode permettant de retourner l'ensemble des sous-types que contient un type.
- TypeManagerTest : Se rapporte à la classe TypeManager du package permettant de gérer la création des types ainsi que leur insertion dans l'arbre. Elle présente deux méthodes, différenciées par leurs arguments, permettant l'ajout d'un type dans l'arbre (makeType()). Nous les avons tout deux testées ainsi que la méthode retournant si deux types sont compatibles (isCompatible()).
- LinguisticFactoryTest : Test de la classe LinguisticFactory (Singleton) qui permet la création d'un TypeManager. Nous avons choisi de tester les méthodes qui apportent les fonctionnalités suivantes :
  - L'ajout d'un type au TypeManager au moyen de sa propre méthode (makeType). Il a fallu faire de même que pour TypeManagerTest, c'est-à-dire tester les deux méthodes permettant cette fonctionnalité malgré que leur seule différence (les éléments pris en argument).
  - L'ajout de concept, simple ou complexe à l'arbre qu'utilise le TypeManager. Ici aussi, nous avons réalisé deux tests selon la forme du concept.
- GraphConceptsTest et GraphNodeDefault : GraphConceptsInterface et GraphNode sont des interfaces que les classes respectives GraphConcepts et GraphNodeDefault implémentent. Ces classes permettent la représentation sous forme de graphe des concepts utilisés et sélectionnés par l'utilisateur au moyen de l'interface graphique. Nous avons testé pour ces classes :
  - Certains accesseurs qui nous semblaient importants dans le sens où ces classes utilisent de nombreux objets d'autres classes, il est donc nécessaire de pouvoir garantir l'accès à ces objets et à leur référence.
  - La méthode permettant la création de la requête qui sera envoyée à Syntox (generateSyntox()). Cette méthode est appelée depuis GraphConcepts et fait appel à son homologue présente dans GraphNodeDefault.

### 6.1.2 Core

Dans ce package se trouvent toutes les classes permettant le lancement de notre application et les outils nécessaires tel que les éléments permettant la gestion de la sauvegarde des projets, un utilitaire regroupant les informations nécessaires pour la base de données et un système de cryptage/décryptage de mot de passe pour sécuriser l'accès

à la base de données. Nous avons choisi de tester particulièrement les classes présentes dans les fichiers PasswordManager.java, Project.java et InfoDB.java. Plus précisément nous avons validé les fonctionnalités suivantes :

- L’encryptage ainsi que le décryptage d’un mot de passe. En effet, comme indiqué dans le cahier des besoins, nous ne souhaitons pas laisser le mot de passe utilisé pour la connexion à la base de données en clair. Il nous a donc fallu crypter une fois la connexion faite mais également décrypter si on doit réutiliser le mot de passe.
- La conservation des informations saisies pour la base de données au moyen de l’objet initBase.
- L’ajout et la suppression de scénarios relatifs à un Projet.

### **6.1.3 Database[Connection/Inspection]**

### **6.1.4 Syntox**

### **6.1.5 Mémoire et temps de calcul**

## **6.2 Résultats**

## Chapitre 7

### Conclusion et perspectives

# Bibliographie

- [1] John Bateman. Natural Language Generation : an introduction and open-ended review of the state of the art. <http://www.fb10.uni-bremen.de/anglistik/langpro/webSPACE/jb/info-pages/nlg/ATG01/>, 1993 (dernier accès : 16 janvier 2013).
- [2] Lionel Clément. Synthèse de texte avec le logiciel Syntox. In AFCEP ATALA, editor, *Actes de la conférence conjointe JEP-TALN-RECITAL*, 2012.
- [3] Meunier F. Combet V., Danlos L. EasyText : an operational NLG System. In *European Workshop on Natural Language Generation*, 2011.
- [4] Laurence Danlos. Ecriture automatique. In *Les cahiers de l'INRIA*, 2010.
- [5] Mourhri et al. Générateur automatique de texte. Mémoire de Projet de Programmation, Université Bordeaux 1, 2012.
- [6] Danlos L. et Roussarie L. *La génération automatique de textes*. 2000.